# INDEKS FILE (TEKS) MENGGUNAKAN SWISH-E

#### by: M. SALSABILA JAMIL

SWISH-e adalah sebuah *tool* yang digunakan untuk meng-indeks teks dalam berbagai format, seperti PDF, html, txt, XML, PostScript, dll. Selain meng-indeks, *tool* ini juga dapat mencari dokumen berdasarkan *query* yang di-*input*-kan. *Tool* ini memiliki banyak fitur/kemampuan yang dimilikinya, contohnya:

- Dapat menentukan stopword list yang hendak digunakan
- Dapat Menentukan direktori (berisi file) yang ingin di-indeks
- Dapat Menentukan jenis file yang di-indeks (PDF?, XML?, email?, txt?, html?, dll)
- Bisa melakukan *stemming* (dalam beberapa bahasa)
- Fast
- Dapat meng-indeks berita dari suatu website (crawling)
- Dapat Mencari dokumen yang mengandung *query* yang dimasukkan
- Dan masih banyak lagi -> Baca Lebih Lanjut

Berikut dijelaskan cara menggunakan tool ini.

Langkah pertama yaitu **DOWNLOAD FILE BERISI TEKS** (disini penulis menggunakan TEKS BERITA)

- 1. Penulis membuat skrip untuk mengunduh berita pada website:
  - KOMPAS: src/spider/spider\_kompas.go
  - TEMPO: src/spider/spider\_tempo.go
  - ANTARA:
    - src/spider/spider\_antara.go
    - src/spider/spider\_antara\_oto.go
- 2. Tema-tema berita yang di-download:
  - o Entertainment/Hiburan
  - o Sport/Olahraga
  - o Tekno
  - Otomotif
- 3. Bagian-bagian HTML yang diambil:
  - Title/Judul
  - Tanggal Terbit
  - Tag (Opsional)
  - Content/Isi
- 4. Berita yang terkumpul Dapat dilihat pada folder:
  - o kompas/
  - o tempo/
  - o antara/
- 5. Selanjutnya dilakukan proses **PREPROCESSING**:
  - Menghapus \n\r
  - Menghapus tanda baca yang dianggap \*TIDAK PENTING

- o Mengubah spasi lebih dari satu menjadi satu spasi
- Lowercase every letter
- Hasil disimpan pada folder:
  - ALL/
  - Secara keseluruhan berjumlah: ~55K

#### Langkah kedua, **STEMMING**:

- 1. Pengertian: Mengubah kata ke bentuk dasarnya, contoh:\_ berjalan -> jalan \_ memancing -> pancing \* menggunakan -> guna
- 2. Tujuan:
  - Sebisa mungkin mengurangi kata yang nantinya akan di-indeks, sehingga jumlah memori yang digunakan semakin sedikit
- 3. Proses *STEMMING* menggunakan pustaka/modul yang dikembangkan oleh RadhiFadlillah dalam bahasa GO, dimana RadhiFadlillah mengambil referensi dari andylibrian yang mengembangkannya dalam bahasa PHP.
- 4. Pustaka (kopi sebahagian dari README.md RadhiFadlillah)

### **Algoritma**

- 1. Algoritma Nazief dan Adriani
- 2. Asian J. 2007. *Effective Techniques for Indonesian Text Retrieval*. PhD thesis School of Computer Science and Information Technology RMIT University Australia. (PDF dan Amazon)
- 3. Arifin, A.Z., I.P.A.K. Mahendra dan H.T. Ciptaningtyas. 2009. *Enhanced Confix Stripping Stemmer and Ants Algorithm for Classifying News Document in Indonesian Language*, Proceeding of International Conference on Information & Communication Technology and Systems (ICTS). (PDF)
- A. D. Tahitoe, D. Purwitasari. 2010. *Implementasi Modifikasi Enhanced Confix Stripping Stemmer Untuk Bahasa Indonesia dengan Metode Corpus Based Stemming*, Institut Teknologi Sepuluh Nopember (ITS) Surabaya, 60111, Indonesia. (PDF)
- 5. Tambahan aturan stemming dari kontributor Sastrawi.

#### Kamus Kata Dasar

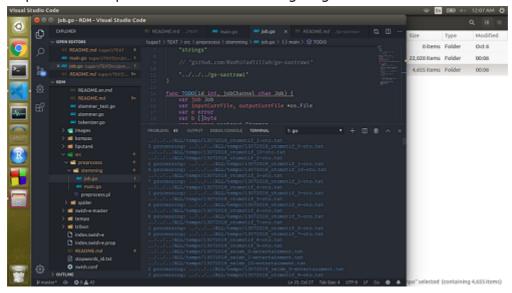
Proses stemming oleh Sastrawi sangat bergantung pada kamus kata dasar. Sastrawi menggunakan kamus kata dasar dari kateglo.com dengan sedikit perubahan.

## Lisensi

Sebagaimana Sastrawi untuk PHP, Go-Sastrawi untuk GO, projek ini juga disebarkan dengan lisensi MIT. Untuk lisensi kamus kata dasar dari Kateglo adalah CC-BY-NC-SA 3.0.

5. Proses *STEMMING* dilakukan menggunakan skrip yang terdapat di folder src/preprocess/stemming/main.go

6. Cuplikan ketika proses STEMMING berlangsung:



- 7. Hasil STEMMING ditaruh di folder:
  - O ALL\_2/kompas
  - ALL\_2/tempo
  - ALL\_2/antara

## Langkah ketiga, INDEXING:

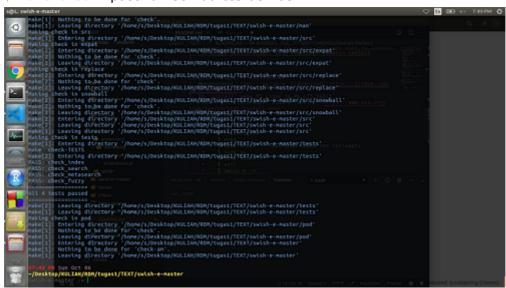
- 1. Menggunakan tool swish-e (download)
- 2. Di-install pada OS Linux 16.04 LTS 64bit
- 3. Proses instalasi dapat dibaca disini
  - o Download
  - Unzip
  - o \$ cd
  - \$ ./configure



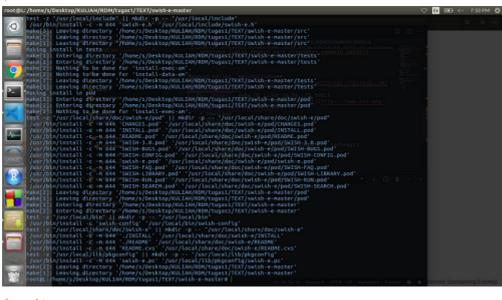
o \$ make



• \$ make check \*pastikan semua tes berhasil



- \$ sudo su
- \$ make install

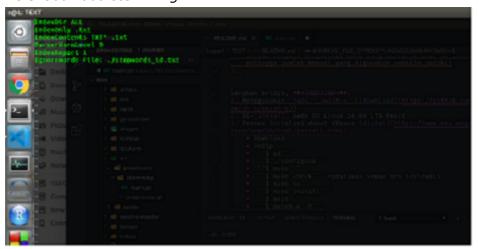


o \$ exit

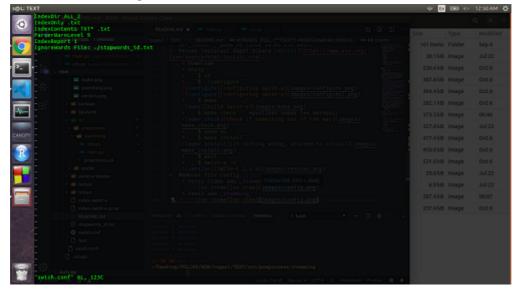
swish-e -V SWISH-E 2.5.8



- 4. Membuat file config. : BACA LEBIH LANJUT
  - Versi tidak ada stemming



Versi ada stemming



5. Konfigurasi proses peng-indeks-an tercantum dalam *file* config yang telah dibuat: **swish.conf**. \*Perlu diperhatikan adanya pemangkasan kata umum (*common words*)

(*stopwords*) menggunakan data *stopwords* bahasa indonesia (**stopwords\_id.txt**) yang dapat di-*download* melalui link ini. Data *Stopwords* ini didapat pada *website* sites.google.com/site/kevinbouge/stopwords-lists.

```
IndexFile ./indeks.swish-e
IndexDir ALL_2
IndexOnly .txt
IndexContents TXT* .txt
ParserWarnLevel 9
IndexReport 1
IgnoreWords File: ./stopwords_id.txt
```

#### swish.conf

o no stem

IndexDir ALL

with stem

IndexDir ALL\_2

6. Dapat dilihat file yang diindeks berjumlah 56295 files

7. Waktu peng-indeks-an: ~10 menit

8. Jumlah *Unique words*:

no stem: ~186Kwith stem: ~162K

- 9. Terlihat perbedaan mencolok antara **no stem** dan **with stem** dalam hal jumlah *Unique words*
- 10. Uji Coba search sebuah kata:
  - o no stem



o with stem



- Perbedaanya tidak terlalu jauh dari hal jumlah dokumen yang berhasil ditemukan menggunakan kata tersebut.
- 11. Jika ingin mencari dokumen dengan jumlah kata lebih dari satu, maka gunakan tanda petik dua ("[query]"), contohnya swish-e -f [index.swish-e] -m 10 -w "jakarta bandung surabaya". Query tersebut akan mencari dokumen yang mengandung kata jakarta AND bandung AND surabaya. Jika dalam query tersebut ada kata yang terdapat dalam daftar stopword, maka akan dihapus/dilewatkan/tidak di proses. Argument dari parameter -f adalah nama file hasil indexing (default: index.swish-e).
  - Query: "jakarta bandung surabaya" atau jakarta AND bandung AND surabaya
     Hit: 390



Query: "pandji pragiwaksono dan raditya dika"
 Hit: 8



Dapat di-intepret sebagai: "cari dokumen yang mengandung kata **pandji AND pragiwaksono AND dan AND raditya AND dika**"

Kata 'dan' tidak diproses karena termasuk dalam daftar stopwords

 Query: "raditya dika AND NOT pandji pragiwaksono" dan "raditya dika OR pandji pragiwaksono"

Hit: 0 dan 71

Dapat di-intepret sebagai:

- "cari dokumen yang mengandung kata raditya AND dika tapi tidak ada kata pandji AND pragiwaksono"
- "cari dokumen yang mengandung kata raditya AND dika atau pandji AND pragiwaksono"



Parameter -m [n] digunakan untuk menampilkan  $top\ n$  dokumen, misalkan -m 10 menampilkan 10 dokumen teratas.

## 12. Arti dari Output (format):

Kolom-1: Ranking

Kolom-2: Lokasi dokumen/file

Kolom-3: Judul/Nama dokumen/file

Kolom-4: Size/Ukuran dokumen (dalam bytes) BACA LEBIH LANJUT

## ---Download---

Semua file yang digunakan dalam projek ini dapat di unduh pada link berikut UNDUH FILE

# github

Versi enak dilihat -> link

## Data

File konfigurasi dapat dilihat di sini