INDEKS FILE (TEKS) MENGGUNAKAN SWISH-E

by: M. SALSABILA JAMIL

SWISH-e adalah sebuah *tool* yang digunakan untuk meng-indeks teks dalam berbagai format, seperti PDF, html, txt, XML, PostScript, dll. Selain meng-indeks, *tool* ini juga dapat mencari dokumen berdasarkan *query* yang di-*input*-kan. *Tool* ini memiliki banyak fitur/kemampuan yang dimilikinya, contohnya:

- Dapat menentukan stopword list yang hendak digunakan
- Dapat menentukan direktori (berisi file) yang ingin di-indeks
- Dapat menentukan jenis file yang di-indeks (PDF?, XML?, email?, txt?, html?, dll)
- Bisa melakukan stemming (dalam beberapa bahasa)
- Fast
- Dapat meng-indeks berita dari suatu website (crawling)
- Dapat Mencari dokumen yang mengandung *query* yang dimasukkan
- Dan masih banyak lagi -> Baca Lebih Lanjut

Berikut dijelaskan cara menggunakan tool ini.

Langkah pertama yaitu **DOWNLOAD FILE BERISI TEKS** (disini penulis menggunakan TEKS BERITA)

- 1. Penulis membuat skrip untuk mengunduh berita pada website:
 - KOMPAS: src/spider/spider_kompas.go
 - TEMPO: src/spider/spider_tempo.go
 - ANTARA:
 - src/spider/spider_antara.go
 - src/spider/spider_antara_oto.go
- 2. Tema-tema berita yang di-download:
 - o Entertainment/Hiburan
 - Sport/Olahraga
 - o Tekno
 - Otomotif
- 3. Bagian-bagian HTML yang diambil:
 - Title/Judul
 - Tanggal Terbit
 - Tag (Opsional)
 - Content/Isi
- 4. Berita yang terkumpul Dapat dilihat pada folder:
 - o kompas/
 - o tempo/
 - o antara/
- 5. Selanjutnya dilakukan proses **PREPROCESSING**:
 - Menghapus \n\r
 - Menghapus tanda baca yang dianggap *TIDAK PENTING

- o Mengubah spasi lebih dari satu menjadi satu spasi
- Lowercase every letter
- Hasil disimpan pada folder:
 - ALL/
 - Secara keseluruhan berjumlah: ~55K

Langkah kedua, **STEMMING**:

- 1. Pengertian: Mengubah kata ke bentuk dasarnya, contoh:
 - berjalan -> jalan
 - memancing -> pancing
 - o menggunakan -> guna
- 2. Tujuan:
 - Sebisa mungkin mengurangi kata yang nantinya akan di-indeks, sehingga jumlah memori yang digunakan semakin sedikit
- 3. Proses *STEMMING* menggunakan pustaka/modul yang dikembangkan oleh RadhiFadlillah dalam bahasa GO, dimana RadhiFadlillah mengambil referensi dari andylibrian yang mengembangkannya dalam bahasa PHP.
- 4. Pustaka (kopi sebahagian dari README.md RadhiFadlillah)

Algoritma

- 1. Algoritma Nazief dan Adriani
- 2. Asian J. 2007. *Effective Techniques for Indonesian Text Retrieval*. PhD thesis School of Computer Science and Information Technology RMIT University Australia. (PDF dan Amazon)
- 3. Arifin, A.Z., I.P.A.K. Mahendra dan H.T. Ciptaningtyas. 2009. *Enhanced Confix Stripping Stemmer and Ants Algorithm for Classifying News Document in Indonesian Language*, Proceeding of International Conference on Information & Communication Technology and Systems (ICTS). (PDF)
- A. D. Tahitoe, D. Purwitasari. 2010. *Implementasi Modifikasi Enhanced Confix Stripping Stemmer Untuk Bahasa Indonesia dengan Metode Corpus Based Stemming*, Institut Teknologi Sepuluh Nopember (ITS) Surabaya, 60111, Indonesia. (PDF)
- 5. Tambahan aturan stemming dari kontributor Sastrawi.

Kamus Kata Dasar

Proses stemming oleh Sastrawi sangat bergantung pada kamus kata dasar. Sastrawi menggunakan kamus kata dasar dari kateglo.com dengan sedikit perubahan.

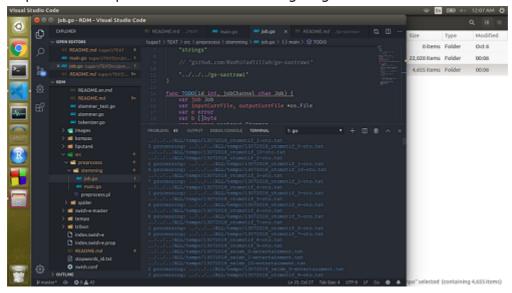
Lisensi

Sebagaimana Sastrawi untuk PHP, Go-Sastrawi untuk GO, projek ini juga disebarkan dengan lisensi MIT. Untuk lisensi kamus kata dasar dari Kateglo adalah CC-BY-NC-SA 3.0.

5. Proses STEMMING dilakukan menggunakan skrip yang terdapat di folder

src/preprocess/stemming/main.go

6. Cuplikan ketika proses STEMMING berlangsung:



- 7. Hasil STEMMING ditaruh di folder:
 - O ALL_2/kompas
 - ALL_2/tempo
 - ALL_2/antara

Langkah ketiga, INDEXING:

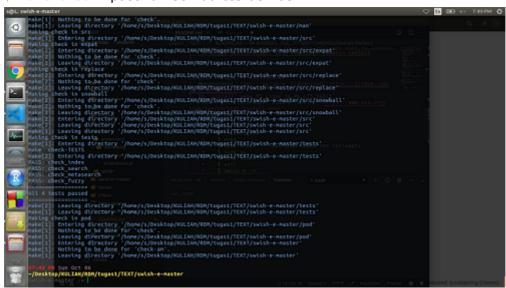
- 1. Menggunakan tool swish-e (download)
- 2. Di-install pada OS Linux 16.04 LTS 64bit
- 3. Proses instalasi dapat dibaca disini
 - o Download
 - Unzip
 - o \$ cd
 - \$./configure



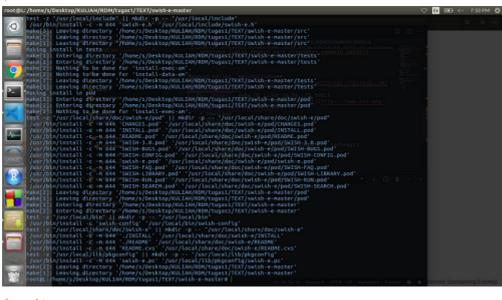
o \$ make



• \$ make check *pastikan semua tes berhasil



- \$ sudo su
- \$ make install

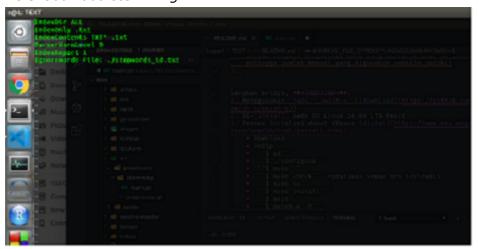


o \$ exit

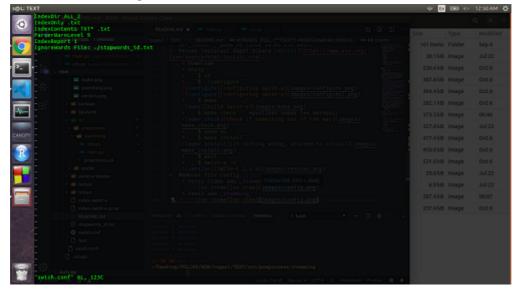
swish-e -V SWISH-E 2.5.8



- 4. Membuat file config. : BACA LEBIH LANJUT
 - Versi tidak ada stemming



Versi ada stemming



5. Konfigurasi proses peng-indeks-an tercantum dalam *file* config yang telah dibuat: **swish.conf**. *Perlu diperhatikan adanya pemangkasan kata umum (*common words*)

(*stopwords*) menggunakan data *stopwords* bahasa indonesia (**stopwords_id.txt**) yang dapat di-*download* melalui link ini. Data *Stopwords* ini didapat pada *website* sites.google.com/site/kevinbouge/stopwords-lists.

```
IndexFile ./indeks.swish-e
IndexDir ALL_2
IndexOnly .txt
IndexContents TXT* .txt
ParserWarnLevel 9
IndexReport 1
IgnoreWords File: ./stopwords_id.txt
```

swish.conf

o no stem

IndexDir ALL

with stem

IndexDir ALL_2

6. Dapat dilihat file yang diindeks berjumlah 56295 files

7. Waktu peng-indeks-an: ~10 menit

8. Jumlah *Unique words*:

no stem: ~186Kwith stem: ~162K

- 9. Terlihat perbedaan mencolok antara **no stem** dan **with stem** dalam hal jumlah *Unique words*
- 10. Uji Coba search sebuah kata:
 - o no stem



o with stem



- Perbedaanya tidak terlalu jauh dari hal jumlah dokumen yang berhasil ditemukan menggunakan kata tersebut.
- 11. Jika ingin mencari dokumen dengan jumlah kata lebih dari satu, maka gunakan tanda petik dua ("[query]"), contohnya swish-e -f [index.swish-e] -m 10 -w "jakarta bandung surabaya". Query tersebut akan mencari dokumen yang mengandung kata jakarta AND bandung AND surabaya. Jika dalam query tersebut ada kata yang terdapat dalam daftar stopword, maka akan dihapus/dilewatkan/tidak di proses. Argument dari parameter -f adalah nama file hasil indexing (default: index.swish-e).
 - Query: "jakarta bandung surabaya" atau jakarta AND bandung AND surabaya
 Hit: 390



Query: "pandji pragiwaksono dan raditya dika"
 Hit: 8



Dapat di-intepret sebagai: "cari dokumen yang mengandung kata **pandji AND pragiwaksono AND dan AND raditya AND dika**"

Kata 'dan' tidak diproses karena termasuk dalam daftar stopwords

 Query: "raditya dika AND NOT pandji pragiwaksono" dan "raditya dika OR pandji pragiwaksono"

Hit: 0 dan 71

Dapat di-intepret sebagai:

- "cari dokumen yang mengandung kata raditya AND dika tapi tidak ada kata pandji AND pragiwaksono"
- "cari dokumen yang mengandung kata raditya AND dika atau pandji AND pragiwaksono"



Parameter -m [n] digunakan untuk menampilkan $top\ n$ dokumen, misalkan -m 10 menampilkan 10 dokumen teratas.

12. Arti dari Output (format):

Kolom-1: Ranking

Kolom-2: Lokasi dokumen/file

Kolom-3: Judul/Nama dokumen/file

Kolom-4: Size/Ukuran dokumen (dalam bytes) BACA LEBIH LANJUT

---Download---

Semua file yang digunakan dalam projek ini dapat di unduh pada link berikut UNDUH FILE

github

Versi enak dilihat -> link

Data

File konfigurasi dapat dilihat di sini