INDEKS FILE (TEKS) MENGGUNAKAN SWISH-E

by: M. SALSABILA JAMIL (mailto:jamilsalsabila@gmail.com)

SWISH-e (https://www.esa.org/tiee/search/html/index.html) adalah sebuah tool yang digunakan untuk meng-indeks teks dalam berbagai format, seperti PDF, html, txt, XML, PostScript, dll. Selain meng-indeks, tool ini juga dapat mencari dokumen berdasarkan query yang di-input-kan. Tool ini memiliki banyak fitur/kemampuan yang dimilikinya, contohnya:

- Dapat menentukan stopword list yang hendak digunakan
- Dapat Menentukan direktori (berisi file) yang ingin di-indeks
- Dapat Menentukan jenis file yang di-indeks (PDF?, XML?, email?, txt?, html?, dll)
- Bisa melakukan stemming (dalam beberapa bahasa)
- Fast
- Dapat meng-indeks berita dari suatu website (crawling)
- Dapat Mencari dokumen yang mengandung query yang dimasukkan
- Dan masih banyak lagi -> Baca Lebih Lanjut (https://www.esa.org/tiee/search/html/readme.html)

Berikut dijelaskan cara menggunakan tool ini.

Langkah pertama yaitu DOWNLOAD FILE BERISI TEKS (disini penulis menggunakan TEKS BERITA)

- 1. Penulis membuat skrip untuk mengunduh berita pada website:
 - KOMPAS (https://www.kompas.com): src/spider/spider kompas.go
 - TEMPO (https://www.tempo.co): src/spider/spider tempo.go
 - ANTARA (https://www.antaranews.com):
 - src/spider/spider antara.go
 - src/spider/spider_antara_oto.go
- 2. Tema-tema berita yang di-download:
 - Entertainment/Hiburan
 - Sport/Olahraga
 - Tekno
 - Otomotif
- 3. Bagian-bagian HTML yang diambil:
 - Title/Judul
 - Tanggal Terbit
 - Tag (Opsional)
 - Content/Isi
- 4. Berita yang terkumpul Dapat dilihat pada folder.
 - kompas/
 - tempo/
 - antara/
- 5. Selanjutnya dilakukan proses PREPROCESSING:
 - Menghapus \n\r
 - ∘ Menghapus tanda baca yang dianggap *TIDAK PENTING
 - o Mengubah spasi lebih dari satu menjadi satu spasi
 - Lowercase every letter
 - Hasil disimpan pada folder:
 - ALL
 - Secara keseluruhan berjumlah: ~55K

Langkah kedua, STEMMING:

1. Pengertian:

Mengubah kata ke bentuk dasarnya, contoh:

- berjalan -> jalan
- memancing -> pancing
- menggunakan -> guna
- 2. Tujuan

Sebisa mungkin mengurangi kata yang nantinya akan di-indeks, sehingga jumlah memori yang digunakan semakin sedikit

- 3. Proses STEMMING menggunakan pustaka/modul yang dikembangkan oleh RadhiFadlillah (https://github.com/RadhiFadlillah/go-sastrawi) dalam bahasa GO (https://golang.org/), dimana RadhiFadlillah mengambil referensi dari andylibrian (https://github.com/sastrawi) yang mengembangkannya dalam bahasa PHP.
- 4. Pustaka (kopi sebahagian dari README.md RadhiFadlillah (https://github.com/RadhiFadlillah/go-sastrawi))

Algoritma

- 1. Algoritma Nazief dan Adriani
- Asian J. 2007. Effective Techniques for Indonesian Text Retrieval. PhD thesis School of Computer Science and Information Technology RMIT University Australia. (PDF (http://researchbank.mit.edu.au/eserv/rmit:6312/Asian.pdf) dan Amazon (https://www.amazon.com/Effective-Techniques-Indonesian-Text-Retrieval/dp/3639021649))
- Arifin, A.Z., I.P.A.K. Mahendra dan H.T. Ciptaningtyas. 2009. Enhanced Confix Stripping Stemmer and Ants Algorithm for Classifying News Document in Indonesian Language, Proceeding of International Conference on Information & Communication Technology and Systems (ICTS). (PDF (http://personal.its.ac.id/files/pub/2623-aguszabaru%2021%20d%20VIP%20enhanced-confix-stripping-stem.pdf))
- A. D. Tahitoe, D. Purwitasari. 2010. Implementasi Modifikasi Enhanced Confix Stripping Stemmer Untuk Bahasa Indonesia dengan Metode Corpus Based Stemming, Institut Teknologi Sepuluh Nopember (ITS) – Surabaya, 60111, Indonesia. (PDF (http://digilib.its.ac.id/public/ITS-Undergraduate-14255-paperpdf.pdf))
- 5. Tambahan aturan stemming dari kontributor Sastrawi (https://github.com/sastrawi/sastrawi/graphs/contributors).

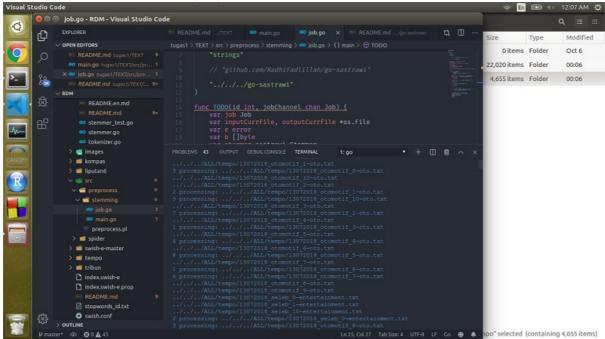
Kamus Kata Dasar

Proses stemming oleh Sastrawi sangat bergantung pada kamus kata dasar. Sastrawi menggunakan kamus kata dasar dari kateglo.com (http://kateglo.com) dengan sedikit perubahan.

Lisensi

Sebagaimana <u>Sastrawi (https://github.com/sastrawi/sastrawi)</u> untuk PHP, <u>Go-Sastrawi (https://github.com/RadhiFadlillah/go-sastrawi)</u> untuk GO, projek ini juga disebarkan dengan lisensi <u>MIT (http://choosealicense.com/licenses/mit/)</u>. Untuk lisensi kamus kata dasar dari Kateglo adalah CC-BY-NC-SA 3.0 (https://github.com/ivanlanin/kateglo#lisensi-isi).

- 5. Proses STEMMING dilakukan menggunakan skrip yang terdapat di folder src/preprocess/stemming/main.go
- 6. Cuplikan ketika proses STEMMING berlangsung:



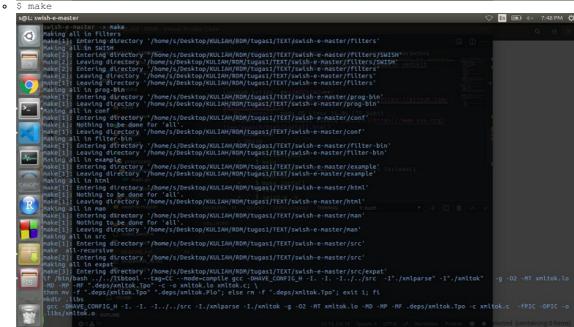
- 7. Hasil STEMMING ditaruh di folder:
 - ALL_2/kompas
 - ALL_2/tempo
 - ALL_2/antara

Langkah ketiga, INDEXING:

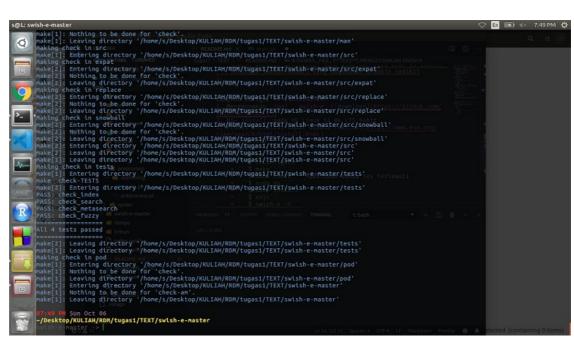
- 1. Menggunakan tool swish-e (download (https://github.com/swish-e/swish-e))
- 2. Di-install pada OS Linux 16.04 LTS 64bit
- 3. Proses instalasi dapat dibaca disini (https://www.esa.org/tiee/search/html/install.html)
 - Download

- Unzip
- \$ cd
- \$./configure





make check *pastikan semua tes berhasil

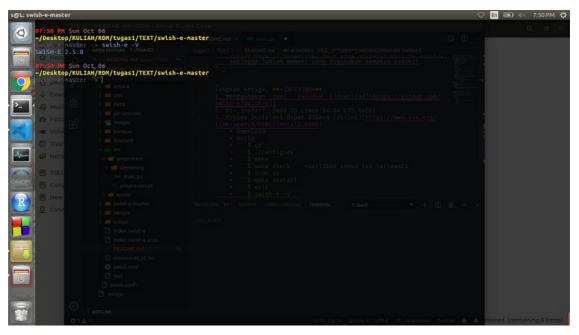


- \$ sudo su
- \$ make install



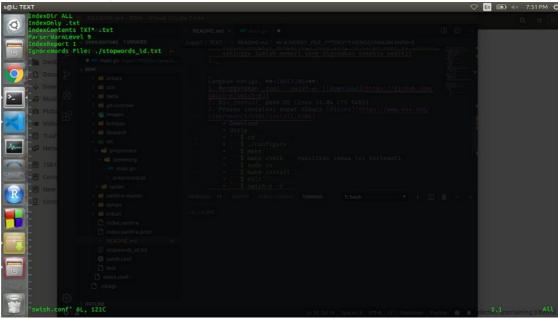
- \$ exit
- \$ swish-e -V

SWISH-E 2.5.8



4. Membuat file config.: BACA LEBIH LANJUT (https://www.esa.org/tiee/search/html/swish-config.html)

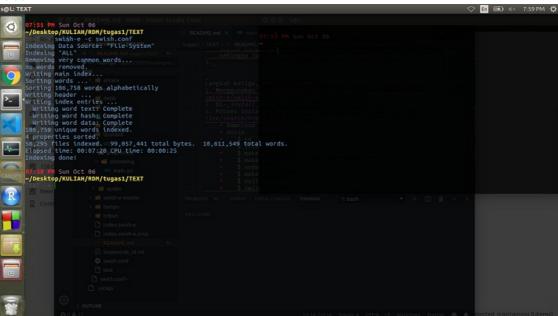
• Versi tidak ada stemming



Versi ada stemming



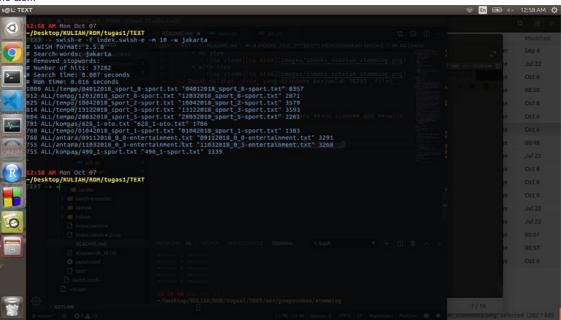
- 5. Konfigurasi proses peng-indeks-an tercantum dalam file config yang telah dibuat: swish.conf. Perlu diperhatikan adanya pemangkasan kata umum (common words)(stopwords) menggunakan data stopwords bahasa indonesia (stopwords_id.txt*) yang dapat di-download melalui link ini (https://docs.google.com/viewer? a=v&pid=sites&srcid=ZGVmYXVsdGRvbWFpbnxrZXZpbmJvdWdlfGd4Ojl4ZWY0ZGVkMzJjM2FkYWU). Data Stopwords ini didapat pada website sites.google.com/site/kevinbouge/stopwords-lists (https://sites.google.com/site/kevinbouge/stopwords-lists).
 - no stem



o with stem



- 6. Dapat dilihat file yang diindeks berjumlah 56295 files
- 7. Waktu peng-indeks-an: ~10 menit
- 8. Jumlah Unique words:
 - no stem: ~186Kwith stem: ~162K
- 9. Terlihat perbedaan mencolok antara no stem dan with stem dalam hal jumlah Unique words
- 10. Uji Coba search sebuah kata:
 - no stem



with stem



- 11. Jika ingin mencari dokumen dengan jumlah kata lebih dari satu, maka gunakan tanda petik dua ("[query]"), contohnya swish-e -f [index.swish-e] -m 10 -w "jakarta bandung surabaya". Query tersebut akan mencari dokumen yang mengandung kata jakarta AND bandung AND surabaya. Jika dalam query tersebut ada kata yang terdapat dalam daftar stopword, maka akan dihapus/dilewatkan/tidak di proses. Argument dari parameter -f adalah nama file hasil indexing (default: index.swish-e).
- 12. Arti dari Output (format):
 - Kolom-1: Ranking
 - o Kolom-2: Lokasi dokumen/file
 - Kolom-3: Judul/Nama dokumen/file
 - Kolom-4: Size/Ukuran dokumen (dalam bytes)
 BACA LEBIH LANJUT (https://www.esa.org/tiee/search/html/swish-config.html)

---Download---

Semua file yang digunakan dalam projek ini dapat di unduh pada link berikut <u>UNDUH FILE (https://drive.google.com/open?id=1e0Qtx1KgmzGm3IJGxHW3qBkp9F3BToBb)</u>